

任意形状聚类的 SPK-means 算法

侯延琛,赵金东*

(烟台大学计算机与控制工程学院,山东 烟台 264010)

摘要:针对 K -means 聚类算法仅以质心作为聚类依据,在处理非圆球形数据集时效果不理想,数据集的形状特性未得到体现的问题,提出一种基于形状的 K -means 算法(shape K -means, SPK-means)。将判定点到不同簇中质心以及点到不同簇的最近边缘点的距离作为判定规则,使其具备对任意形状的数据集进行聚类的能力。设置两种不同的数据集进行聚类试验,结果表明,SPK-means 聚类算法在处理非圆球形数据集时,其结果遵循原数据集的形状特征。

关键词: K -means; 高精度; 边缘点; 形状; 快速聚类

中图分类号: TP311.13 **文献标志码:** A

引用格式: 侯延琛,赵金东. 任意形状聚类的 SPK-means 算法[J]. 山东大学学报(工学版), 2023, 53(2): 87-92.

HOU Yanchen, ZHAO Jindong. SPK-means: a clustering algorithm for arbitrary shapes[J]. Journal of Shandong University (Engineering Science), 2023, 53(2): 87-92.

SPK-means: a clustering algorithm for arbitrary shapes

HOU Yanchen, ZHAO Jindong*

(School of Computer and Control Engineering, Yantai University, Yantai 264010, Shandong, China)

Abstract: Considered that the K -means clustering algorithm only took the center of mass as the clustering basis, the effect was not ideal when processing non-spherical data sets, and the shape characteristics of the data sets were not reflected. This research proposed an improved K -means algorithm (shape K -means, SPK-means) which took the distance between the decision point and the center of mass in different clusters and the nearest edge point from the point to different clusters as the decision rule. This enabled it to cluster data sets of arbitrary shapes. Two different data sets were set for clustering in the experiment, and the results showed that the results of SPK-means clustering algorithm followed the shape characteristics of the original data set when processing non-circular spherical data sets.

Keywords: K -means; high-precision; edge point; shape; fast clustering

0 引言

大数据时代下如何更加高效地处理数据、利用数据成为目前亟待解决的热点问题。大数据具有数量爆炸、知识贫瘠的特点,在此环境下数据挖掘成为继网络之后的又一技术热点。

数据挖掘中如何将海量数据行之有效地分类、聚集是该研究方向的核心问题^[1-2]。数据挖掘旨在发现大数据中潜在稀疏的联系,达到预测信息的目的。在数据挖掘领域内,将抽象的对象按照一定条

件分为多个类的过程称为聚类^[3],数据挖掘能否达到预期目标的关键就是聚类算法的选取^[4]。聚类算法的发展已有近 70 a 的历史,在此期间发展了针对各种数据特点的不同聚类算法,其中 K -means 算法是最经典的无监督聚类算法之一^[5]。 K -means 原理简单易懂,算法效率十分优异,具有较快的收敛速度,且不需要大量的计算资源,在不同的应用场景中通常都能发挥优异的效果, K -means 算法非常适合作为大数据环境下的聚类算法^[6]。但是 K -means 同样存在着一些问题,针对这些问题,不同学者提出了不同的解决办法^[7-9]。传

收稿日期:2022-10-12

基金项目:国家自然科学基金项目(61972360);山东省自然科学基金(ZR2020MF148, ZR2020QF108)

第一作者简介:侯延琛(1997—),男,山东潍坊人,硕士研究生,主要研究方向为流数据聚类。E-mail: 741244262@qq.com

* 通信作者简介:赵金东(1974—),男,山东滨州人,副教授,博士,主要研究方向为区块链。E-mail: zhjdong@ytu.edu.cn

统的 K -means 算法对初始质心点非常敏感,聚类结果过度依赖原始质心的选择^[10-11],针对这个问题,文献[12]将最大最小距离算法与传统的 K -means 算法相结合,提出一种改进的 K -means 聚类算法,有效解决了传统算法对初始质心选择依赖性较大和容易陷入局部最小解的两个缺点^[13-14]。 K -means 算法在应用方面需要多次迭代来综合最后的聚类结果,然而对于大量数据进行多次迭代的代价很高,文献[15]通过引入预聚集来扩展 K -means 算法,使其可以重用之前的聚类结果。针对 K -means 算法存在对特殊数据点敏感的问题,文献[16]在 K -means 聚类过程中,提出一种新的隶属度方程,并给出初始聚类中心点的求解方法,以减少初始点随机选取带来的风险,解决了传统 K -means 算法易陷入局部收敛、易受噪声影响的问题。关于 K -means 并行化计算的问题,文献[17]提出一种基于 K -means 算法的并行批聚类算法,该算法将数据集分割成相等的分区,减少了计算量的指数增长,其目的是在提高聚类速度的同时保留数据集的特征。

K -means 算法是基于距离判断的算法,在聚类效果上呈现出圆形、球形的效果,出现这种效果的原因是 K -means 算法具有各向同性。实际数据集可能呈现各项异性, K -means 算法在处理这种类型的数据集时表现不佳。因此,本研究对 K -means 算法进行改进,提出一种基于形状的 K -means 算法(shape K -means, SPK-means),提高了 K -means 算法对各向异性数据集的收敛效果。

1 问题描述

1.1 K -means 算法的实现原理

K -means 算法遵循相似性原则,将拥有相同特征的元素归为同一类中,其算法流程如下。

(1) 对给定的数据集 $\{x_1, x_2, x_3, \dots, x_n\}$, 随机选取 $\mu_1, \mu_2, \dots, \mu_k \in x_n$ 。 $\mu_1, \mu_2, \dots, \mu_k$ 表示 k 个初始质心点, θ_j 表示质心为 μ_j 的簇。

(2) 对 $x_i \in \{x_1, x_2, \dots, x_n\}$, 求 x_i 到各质心点 $\{\mu_1, \mu_2, \dots, \mu_k\}$ 的欧氏距离^[18]

$$d(x_i, \mu_j) = \sqrt{\sum_{j=1}^k (x_i - \mu_j)^2} \quad (1)$$

(3) 对每一个样本 x_i , 计算其所属簇

$$c^{(x_i)} = \arg \min_k (d(x_i, \mu_j)) \quad (2)$$

(4) 对于 x_i 的所属簇 θ_i , 对其质心 μ_i 进行多次迭代:

$$\mu_i = \frac{1}{|\theta_i|} \sum_{x_i \in \theta_i} x_i, \quad (3)$$

式中: $|\theta_i|$ 表示簇 θ_i 中元素的个数。至此单次聚类过程结束。

质心重复执行多次迭代过程,迭代终止的条件一般分为两种:一种是数据集中最后一位数据 x_n 完成聚类后迭代终止,另一种则通过误差平方和准则函数对迭代结果进行评测,该函数式为:

$$H = \sum_{i=1}^k \sum_{x_i \in \theta_i} d(x_i, \mu_i) \quad (4)$$

每次质心迭代完成后,得到评测值 H , 当相邻两次函数值之差 ΔH 小于某一阈值时, K -means 质心迭代过程结束。

1.2 K -means 算法不规则数据集聚类问题

K -means 算法因采用欧氏距离作为判定依据,生成的簇对各个方向的数据有同等的吸引力,因此 K -means 算法适用于具有各向同性特点的数据集,其聚类产生的结果也将呈现出圆球形特征。

然而,对于数据集具有向某一方向延伸的特点时,即数据集具有各向异性时,使用 K -means 算法对其进行聚类会破坏数据本身的形状特征,导致聚类精度下降。图1表示 K -means 算法对各向同性与各向异性数据集的处理结果。图1(a)为各向同性数据集,经过 K -means 聚类算法处理后可以得到较为理想的结果。图1(b)为各向异性数据集, K -means 算法在处理此类数据集时,由于以欧氏距离作参考,同一形状内、距离质心稍远的元素被错误地划分至其他簇内。




图1 K -means 算法对各向同性与各向异性数据集的处理结果

Fig.1 The processing results of isotropic and anisotropic data sets by K -means algorithm

1.3 各向异性数据集聚类错误的原因

传统 K -means 算法对数据点进行判定时,会通过计算当前点到各质心的欧氏距离,通过比较欧氏距离选择距离最近的质心点作为当前点的归属簇。图2展示 K -means 算法在面对各向异性数据集时,当前点判定错误的过程。当前点为 x_i , 此时 K -means 算法计算 x_i 到质心点 μ_1, μ_2 的欧氏距离

r_1, r_2 。由图2可知, $r_1 > r_2$, 此时 K -means 将 x_i 点判定为 μ_2 所属簇。然而实际中, μ_1 簇中的数据点明显距 x_i 最近, 且 μ_1 簇有向 x_i 延展的趋势。此时判定失误将导致后续聚类结果异常, 出现图1(b)中同类不同簇现象。




图2 K -means 算法原理
Fig.2 Principle of K -means algorithm

由图2可知, 原始数据集形状向某一方向突出时, K -means 算法可能会将一个原本连续的自然簇分开聚类到两个簇中, 导致聚类效果不理想。在实际应用场景中, 复杂环境下产生的数据集更加多维, 离散程度更大, K -means 算法的应用必须解决其对各向异性数据集聚类的短板。

因此, 本研究在 K -means 算法的基础上对聚类的判定规则作出修改, 在不改变原有 K -means 算法聚类特点的条件下, 对于各向异性数据集实现随形状聚类效果。

2 算法描述

2.1 问题分析

K -means 算法在处理形状较为狭长、较为发散的数据集时易产生误差, 影响最终的聚类结果。产生偏差的根本原因是 K -means 算法中对点的判定规则较为简单, 仅考虑点到质心点距离, 没有考虑数据集边缘形状的问题, 本研究就此问题提出基于形状的 SPK-means 算法, 其核心在于不仅在聚类过程中考虑当前点到各质心的距离, 还考虑当前点同各簇最近边缘点的距离。最近边缘点在一定程度上表现了当前判定点的形状特性。通过考虑判定点与边缘点和质心点的位置关系, 可以综合判定当前点的所属。

2.2 算法步骤

K -means 算法的聚类结果多为圆球形的原因, 是其仅通过点到质心的距离判断当前点与簇的关系, 判定条件不够全面。实际在判定当前点的所

属问题上, 还需要考虑该点周围的邻点所属。设计 SPK-means 算法时, 将对点和周围邻点的关系作为判断因素, 是整个算法的核心思想。SPK-means 算法的基础步骤如下。

(1) 判断用户输入的 K 值, 当 $K > 2$ 时, 在对当前点进行聚类前, 计算判断点到各个质心点的距离, 通过比较距离得到最接近判断点的两个质心, 按照 $K = 2$ 的情况进行聚类; 若 $K = 2$, 则如图3所示, P 是待判断的点, A 和 B 分别是两个簇的质心点, 遍历 A 和 B 两簇中距离点 P 最近的边缘点, 得到两点 a 和 b , 分别记录 a 和 b 到点 P 的距离 L_1 、 L_2 ; 计算点 P 到 A 和 B 的距离 d_1 、 d_2 。




图3 SPK-means 判断原理
Fig.3 SPK-means judgment principle

(2) 比较距离 L_1 和 d_2 的大小关系, 得到距离 L_1 小于距离 d_2 , 此时点 P 应当聚类到 A 簇中, 将这个结果记作 R_1 ; 重新比较距离 L_2 和 d_1 , 得到比较结果 L_2 大于 d_1 , 此时点 P 同样应当聚类到 A 簇, 将这个结果记作 R_2 。

(3) 比较结果 R_1 和 R_2 , 若两次结果点 P 都划分到同一个簇中, 则认定结果正确, 储存判断结果并循环执行对下一个点做聚类判断; 若两次结果不一致, 则点 P 属于特殊点, 此时按照传统 K -means 算法判定点 P 会出现误判情况。当 P 为特殊点时, SPK-means 需要执行额外的判定规则。

特殊点判定规则将结合图4说明。设图4(a)黑色点 P 为当前点, 可以看到点 P 距离绿色簇的边缘点更近, 符合该簇的延伸趋势, 应当聚类到绿色簇中。

然而根据传统 K -means 算法中点 P 到两个簇的质心距离可以看出 $L_1 > L_2$, 此时点 P 应该被划分到右侧蓝色簇中。而 SPK-means 算法需要进一步判定点 P 和各个簇边缘点之间的关系。

如图4(b)所示, SPK-means 算法遍历点 P 到两个簇中所有点的距离, 找到距离 P 点最近的两边缘

点 a 和 b , 记录两点到点 P 的距离 d_1, d_2 。

如图 4(c) 所示, 接下来对点 P 按照上述做两次基础比较, 此时发现两次结果分别将点 P 划分到了 A 和 B 两个不同的簇中, 使得聚类结果不唯一, 需要做进一步判断处理。

如图 4(d) 所示, 将两簇的质心相连得到一条直线, 分别对 P 点以及两簇最近边缘点 a 和 b 做到直线的垂线, 在两簇的连线上得到 3 个投影点 a', P', b' , 比较距离 l_1 和 l_2 , 将点 P 聚类到距离较小者的簇

中, 判定过程结束。

如图 4(e) 所示, 经过 SPK-means 算法聚类后, P 点正确聚类到绿色簇中。

在这个过程中, 设定当前点与两边缘点在质心连线方向上的投影距离为有效距离, 采用这样的判定标准是遵循 K -means 的原始规定, 即考虑判定点与各质心的距离。通过这种方式进行聚类, 兼顾了当前点与边缘点和质心点的位置关系, 使得结果更符合原数据集的形状特点。




图4 特殊点的判定规则

Fig.4 Judgment rules of special points

2.3 算法流程

算法 SPK-means 算法

参数: 聚类结果簇数 K

输入: 数据集 $D_{\text{ata}}[x_1, x_2, \dots, x_n]$

输出: 具有形状的聚类结果 R

- 1 设定簇数 $K \leftarrow m$; 确定质心集 $c_{\text{centroid}}[k_1, k_2, k_3, \dots, k_m]$
- 2 for each $x_i \in D_{\text{ata}}$ do
- 3 for each $k^j \in c_{\text{centroid}}$ do
- 4 计算欧氏距离 $|x_i k_j|$; Get 最小距离 $|x_i k_j|$ 与次小距离 $|x_i k_l|$
- 5 for each $\theta_i \in k_j$ do
- 6 Get 欧氏距离 $|x_i \theta_j|$; Get 最小距离 $|x_i \theta_j|$
- 7 for each $\theta_i \in k_l$ do
- 8 Get 欧氏距离 $|x_i \theta_l|$; Get 最小距离 $|x_i \theta_l|$
- 9 if $|x_i k_j| > |x_i \theta_l|$ 且 $|x_i k_l| < |x_i \theta_j|$
- 10 $c^{(x_i)} \leftarrow k_l$

- 11 end if
- 12 if $|x_i k_j| < |x_i \theta_l|$ 且 $|x_i k_l| > |x_i \theta_j|$
- 13 $c^{(x_i)} \leftarrow k_j$
- 14 end if
- 15 else if $|x_i k_j| > |x_i \theta_l|$ 且 $|x_i k_l| > |x_i \theta_j|$
- 16 Create $L_{jl} \leftarrow$ 连接 k_j, k_l ; 做 x_i, θ_j, θ_l 在 L_{jl} 上的垂直投影 $x_1^i, \theta_1^j, \theta_1^l$
- 17 Get 欧氏距离 $|\theta_1^j x_1^i|$; Get 欧氏距离 $|\theta_1^l x_1^i|$
- 18 if $|\theta_1^j x_1^i| > |\theta_1^l x_1^i|$
- 19 $c^{(x_i)} \leftarrow k_j$
- 20 end if
- 21 else
- 22 $c^{(x_i)} \leftarrow k_l$
- 23 end if
- 24 end for
- 25 end for
- 26 return R

3 仿真试验

本研究对 SPK-means 算法的聚类效果进行了综合测试,在多种不同数据集中与传统 K-means 算法以及基于密度的聚类算法(density-based spatial clustering of applications with noise, DBSCAN)进行比较。

本次试验环境为 Intel® Core (TM) i7-7500U、8 GB 内存、GTX940MX 显卡、Windows 10 操作系统、PyCharm 2019.3.5。代码使用的是 python 语言编写。

3.1 SPK-means 与 K-means 算法的对比

本节试验数据集是生成了一组带有各向异性

特征的数据集,设置初始参数 $K=2$ 。

试验使用的数据集如图 5(a) 所示,可以看到数据集分为两个自然簇,左上角的簇呈圆形,适合 K-means 算法的计算,右下角的簇虽较为狭长,且向左上方延伸,但仍是连续的,因此中间较为稀疏的点应当归为右下方的簇中。这些点在 K-means 原始算法中由于对距两个质心点的距离进行比较,其结果应当化为左上方的圆形簇中,如图 5(b) 所示,结果表明 K-means 算法无法正确处理这一类数据集。图 5(c) 为 SPK-means 算法处理该数据集的结果,可以发现 K-means 算法中误判的点在 SPK-means 算法中得到正确聚类。




图 5 K-means 与 SPK-means 的处理结果对比

Fig.5 Comparison of processing results between K-means and SPK-means

3.2 SPK-means 与 DBSCAN 算法的比较

DBSCAN 算法是以密度作为聚类标准的聚类算法,其算法核心是:对于一个簇中的每个点,要求在给定的半径领域内所包含的对象个数不能小于给定的最小值 $M_{in}^{[19]}$ 。

DBSCAN 算法在处理密度相对较大的数据集时可以很好地保证原始数据集的形状,在处理不规则形状数据集方面具有代表性,因此本节设置试验比较 SPK-means 算法与 DBSCAN 算法的聚类效果。本阶段所使用的数据集是经典的 Jain 数据集^[20],如图 6(a) 所示,Jain 数据集由两个半圆

形簇构成,位于上方的簇较为稀疏,下方的簇比较密集。

图 6(b) 是 Jain 数据集在 DBSCAN 算法处理以后所得到的试验结果,可以看到在 kps 参数为 2.5 时,聚类效果最佳。其中左侧两点为噪声点,黄色部分和绿色部分分别代表两个不同的簇。

图 6(c) 为 SPK-means 算法对 Jain 数据集进行处理的结果,可以看到聚类结果基本与 DBSCAN 效果一致。图 6(c) 中黄色点是两个簇的质心,红色和蓝色分别代表两个簇。由此证明 SPK-means 聚类算法对任意形状特征的数据集具有有效性。




图 6 SPK-means 与 DBSCAN 结果的比较

Fig.6 Comparison of SPK-means and DBSCAN result

3.3 算法复杂度分析

传统的 K-means 算法的时间复杂度是

$O(nkT_1)^{[21]}$,其中 n 是数据集中需要判断的点的个数, k 是算法初始需要输入的聚类簇数目, T_1 是算

法聚类过程对各个簇质心点的迭代次数。本研究提出的 SPK-means 算法由于需要找到簇中距离判断点最近的边缘点,并遍历已知的簇中全部的点,因此算法复杂度为 $O(n^2kT_1)$ 。本算法考虑数据集原有的形状因素,在判断时同时考虑了质心点和边缘点,牺牲了部分速度,取而代之的是提升了 K -means 算法的精度,使得 K -means 算法聚类形状不再固定为圆球形,适用于任意连续的数据集。

4 结论

针对 K -means 算法无法正确聚类有形状特征数据集的问题,本研究对于 K -means 进行改进,提出 SPK-means 算法,在聚类过程中结合了判断点到质心和边缘点的距离的判定规则,解决了传统 K -means 算法中对不规则簇进行判定时会产生偏差的问题。在实际场景中, K -means 算法以其简单高效的特点受到广泛应用,本研究的改进将进一步增加 K -means 算法的应用范围。

由于增加了对簇中边缘点距离的计算,SPK-means 算法也提高了算法复杂度的阶数,在面对大型或海量数据时,耗时将大于经典的 K -means 算法。针对这个问题,我们下一步将继续研究边缘点的选取优化方法,降低算法的运算复杂度,提升和改善 SPK-means 算法的效率;另外,也需要进一步将 SPK-means 算法进行并行化设计,使其在集群环境下并行计算,对海量数据进行聚类。

参考文献:

- [1] LU Z. Research on the application of computer data mining technology in the era of big data[J]. Journal of Physics Conference Series, 2021, 1744(4): 042118.
- [2] 韩子莹. 大数据技术应用的伦理探究[D]. 北京:北京邮电大学, 2019.
HAN Ziyang. Ethical exploration of the application of big data technology[D]. Beijing: Beijing University of Posts and Telecommunications, 2019.
- [3] LI Y, WU H. A clustering method based on K -means algorithm[J]. Physics Procedia, 2012, 25: 1104-1109.
- [4] 姬强, 孙艳丰, 胡永利, 等. 深度聚类算法研究综述[J]. 北京工业大学学报, 2021, 47(8): 912-924.
JI Qiang, SUN Yanfeng, HU Yongli, et al. Review of clustering with deep learning[J]. Journal of Beijing University of Technology, 2021, 47(8): 912-924.
- [5] 甘井中, 杨秀兰, 吕洁, 等. 人工智能中无监督学习算法综述[J]. 海峡科技与产业, 2019(1): 134-135.
GAN Jingzhong, YANG Xiulan, LÜ Jie, et al. A review of unsupervised learning algorithms in artificial intelligence[J]. Straits Technology and Industry, 2019(1): 134-135.
- [6] 任远航. 面向大数据的 K -means 算法综述[J]. 计算机应用研究, 2020, 37(12): 3528-3533.
REN Yuanhang. Survey of K -means algorithm on big data[J]. Application Research of Computers, 2020, 37(12): 3528-3533.
- [7] 董文静. K -means 算法综述[J]. 信息与电脑, 2021, 33(11): 76-78.
DONG Wenjing. Brief survey of K -means clustering algorithms[J]. Information and Computer, 2021, 33(11): 76-78.
- [8] 李汉波, 魏福义, 张嘉龙, 等. 基于相异性邻域的改进 K -means 算法[J]. 现代信息科技, 2021, 5(7): 67-70.
LI Hanbo, WEI Fuyi, ZHANG Jialong, et al. Improved K -means algorithm based on dissimilarity neighborhood[J]. Modern Information Technology, 2021, 5(7): 67-70.
- [9] 崔丹丹. K -means 聚类算法的研究与改进[D]. 合肥:安徽大学, 2012.
CUI Dandan. Research and improvement of K -means clustering algorithm[D]. Hefei: Anhui University, 2012.
- [10] 董秋仙, 朱赞生. 一种新的选取初始聚类中心的 K -means 算法[J]. 统计与决策, 2020, 36(16): 32-35.
DONG Qiuxian, ZHU Zansheng. A new K -means algorithm for selecting initial clustering center[J]. Statistics & Decision, 2020, 36(16): 32-35.
- [11] 郭永坤, 章新友, 刘莉萍, 等. 优化初始聚类中心的 K -means 聚类算法[J]. 计算机工程与应用, 2020, 56(15): 172-178.
GUO Yongkun, ZHANG Xinyou, LIU Liping, et al. K -means clustering algorithm of optimizing initial clustering center[J]. Computer Engineering and Applications, 2020, 56(15): 172-178.
- [12] HEGER J, ABDINE M. Using data mining techniques to investigate the correlation between surface cracks and flange lengths in deep drawn sheet metals[J]. IFAC-PapersOnLine, 2019, 52(13): 851-856.
- [13] FAYYAD U M, REINA C, BRADLEY P S. Initialization of iterative refinement clustering algorithms[J]. Proceedings of the Fourth International Conference on Knowledge Discovery and Data Mining, 1998, 8: 194-198.
- [14] DUDA R O, HART P E. Pattern classification and scene analysis[M]. New York: John Wiley & Sons, 1973.
- [15] MALKI N E, RAVAT F. K -means improvement by dynamic pre-aggregates[C]// Proceedings of the 21st International Conference on Enterprise Information Systems. Heraklion, Crete, Greece: ICEIS, 2019: 133-140.

(下转第 101 页)

- vehicular networks[C]//Proceedings of 2020 IEEE 45th Conference on Local Computer Networks. Sydney, Australia: IEEE, 2020: 413-416.
- [13] WANG Y J, GAO Y, LI Y S, et al. A worker-selection incentive mechanism for optimizing platform-centric mobile crowdsourcing systems[J]. Computer Networks, 2020, 171(22): 107144.
- [14] KANG J W, XIONG Z H, NIVATO D, et al. Incentive mechanism for reliable federated learning: a joint optimization approach to combining reputation and contract theory[J]. IEEE Internet of Things Journal, 2019, 6(6): 10700-10714.
- [15] 仲秋雁, 刘志娟. 考虑工作者信誉的众包质量 EM 评估方法[J]. 科技管理研究, 2018, 38(21): 70-76.
ZHONG Qiuyan, LIU Zhijuan. EM evaluation method of crowdsourcing quality considering worker reputation[J]. Research on Science and Technology Management, 2018, 38(21): 70-76.
- [16] XU T Y, SUN H R, SU Z Y, et al. A quality assessment model for blockchain-based crowdsourcing system[C]//IEEE 24th International Conference on Computer Supported Cooperative Work in Design. Dalian, China: IEEE, 2021: 794-799.
- [17] YUEN M C, KING I, LEUNG K S. Task recommendation in crowdsourcing systems[C]//Proceedings of International Workshop on Crowdsourcing & Data Mining. Beijing, China: Association for Computing Machinery, 2012: 22-26.
- [18] 张宇航, 周晓光, 侯东阳. 综合多要素的地理空间数据众包任务推荐方法[J]. 测绘通报, 2022, 68(1): 84-88.
ZHANG Yuhang, ZHOU Xiaoguang, HOU Dongyang. Recommendation method of geo spatial data crowdsourcing task based on multi elements[J]. Bulletin of Surveying and Mapping, 2022, 68(1): 84-88.
- [19] IPEIROTIS P, PROVOST F, WANG J. Quality management on amazon mechanical turk[C]//ACM SIGKDD Workshop on Human Computation (HCOMP'10). New York, USA: Association for Computing Machinery, 2010: 64-67.
- [20] WELINDER P, BRANSON S, BELONGIE S, et al. The multidimensional wisdom of crowds[C]//Proceedings of the 23rd International Conference on Neural Information Processing Systems; Volume 2. Vancouver, Canada: Curran Associates Inc, 2010: 2424-2432.
- [21] 芮兰兰, 张攀, 黄豪球, 等. 一种面向众包的基于信誉值的激励机制[J]. 电子与信息学报, 2016, 38(7): 1808-1815.
RUI Lanlan, ZHANG Pan, HUANG Haoqiu, et al. Reputation based incentive mechanisms in crowdsourcing[J]. Journal of Electronics & Information Technology, 2016, 38(7): 1808-1815.
- [22] GAO Y L, LI X Y, LI J R, et al. A dynamic-trust-based recruiting framework for mobile crowd sensing[C]//Proceedings of 2017 IEEE International Conference on Communications (ICC). Paris, France: IEEE, 2017: 1-6.
- (编辑: 孙亚彤)

(上接第 92 页)

- [16] GENG X, MU Y, MAO S, et al. An improved K -means algorithm based on fuzzy metrics[J]. IEEE Access, 2020, 1(8): 217416-217424.
- [17] ALGULIYEV R M, ALIGULIYEV R M, SUKHOSTAT L V, et al. Parallel batch K -means for big data clustering[J]. Computers & Industrial Engineering, 2021, 152: 107023.
- [18] ANWARY A R, YU H N, VASSALLO M. Gait evaluation using procrustes and euclidean distance matrix analysis[J]. IEEE Journal of Biomedical and Health Informatics, 2019, 23: 2021-2029.
- [19] ESTER M. A density-based algorithm for discovering clusters in large spatial databases with noise[J]. AAAI Press, 1996, 96: 226-231.
- [20] JAIN A K, LAW M. Data clustering: a user's dilemma[J]. International Conference on Pattern Recognition & Machine Intelligence, 2005, 3766: 1-10.
- [21] 王子龙, 李进, 宋亚飞. 基于距离和权重改进的 K -means 算法[J]. 计算机工程与应用, 2020, 56(23): 87-94.
WANG Zilong, LI Jin, SONG Yafei. Improved K -means algorithm based on distance and weight[J]. Computer Engineering and Applications, 2020, 56(23): 87-94.
- (编辑: 孙亚彤)