

武汉大学

本科毕业论文（设计）

面向任意形状数据的
高效聚类算法研究

姓 名：张 田 越

学 号：2021302111056

专 业：计算机科学与技术

学 院：计算机学院

指导教师：黄 浩 教授

二〇二五年 五月

原创性声明

本人郑重声明：所呈交的论文（设计），是本人在指导教师的指导下，严格按照学校和学院有关规定完成的。除文中已经标明引用的内容外，本论文（设计）不包含任何其他个人或集体已发表及撰写的研究成果。对本论文（设计）做出贡献的个人和集体，均已在文中以明确方式标明。本人承诺在论文（设计）工作过程中没有伪造数据等行为。若在本论文（设计）中有侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：张田越 指导教师签名：黄浩
日 期：2025 年 5 月 14 日

版权使用授权书

本人完全了解武汉大学有权保留并向有关部门或机构送交本论文（设计）的复印件和电子版，允许本论文（设计）被查阅和借阅。本人授权武汉大学将本论文的全部或部分内容编入有关数据进行检索和传播，可以采用影印、缩印或扫描等复制手段保存和汇编本论文（设计）。

作者签名 张田越 指导教师签名：黄浩
日 期：2025 年 5 月 14 日

摘 要

在当今数字化时代，数据以空前的速度和规模不断涌现，对数据的高效处理与精准分析显得尤为重要。聚类作为一种无监督学习方法，能够梳理数据的内在结构和秩序，被广泛应用于数据处理与决策支持的各个领域。

在真实的应用场景中，数据分布往往是不规则的。任意形状聚类因其在处理复杂数据分布和非线性结构上的优势，近年来备受关注。现有方法大多基于密度、邻域关系或图结构的知识来实现任意形状的聚类。然而，在实际情况中，由于数据噪声、维度过高以及簇密度变化等问题，大多数任意形状聚类算法伴随着较高的时间复杂度。一些改进方法通过减少采样点提高运行效率，但会导致采样结果无法保留原有形状分布，从而影响最终的聚类结果。

本文提出了一种面向任意形状数据的高效聚类算法 ECAAD (**Efficient Clustering Algorithm for Arbitrary-Shaped Data**)，为高维复杂数据提供更实用的解决方案。本算法为保持原始数据的形状分布，在数据集中均匀选取采样点。通过构建影响力矩阵，不断迭代调整采样点位置，形成更清晰的聚类结构。最后，基于类间最小距离对代表点进行凝聚聚类，生成最终的聚类结果。ECAAD 算法在真实数据集以及合成数据集上的测试表明，其在运行效率、聚类准确率方面均优于现有代表性聚类算法，证明了该算法的高实用性。

关键词：任意形状聚类；形状保持采样；凝聚聚类

ABSTRACT

In today's digital era, data is emerging at an unprecedented speed and scale, making efficient processing and accurate analysis critically important. As an unsupervised learning method, clustering can uncover the inherent structure and order within data, and it has been widely applied in various fields of data processing and decision support.

In real-world scenarios, data distributions are often irregular. Arbitrary-shaped clustering has gained significant attention in recent years due to its advantages in handling complex data distributions and nonlinear structures. Most existing methods rely on density, neighborhood relationships, or graph-based techniques to achieve arbitrary-shaped clustering. However, in practice, due to issues such as data noise, high dimensionality, and varying cluster densities, most arbitrary-shaped clustering algorithms suffer from high computational complexity. Some improved methods enhance efficiency by reducing sample points, but this may compromise the preservation of the original shape distribution, thereby affecting the final clustering results.

This paper proposes ECAAD (Efficient Clustering Algorithm for Arbitrary-Shaped Data), providing a more practical solution for high-dimensional and complex datasets. To maintain the original shape distribution, our algorithm uniformly selects sample points from the dataset. By constructing an influence matrix and iteratively adjusting the positions of sample points, a clearer clustering structure is formed. Finally, agglomerative clustering is performed on representative points based on the minimum inter-class distance to generate the final clustering results. Experiments on both real-world and synthetic datasets demonstrate that ECAAD outperforms existing representative clustering algorithms in terms of computational efficiency and clustering accuracy, proving its high practicality.

Keywords: Arbitrary Shaped Clustering; Shape Preserving Sampling; Agglomerative Clustering

目 录

摘 要.....	I
ABSTRACT.....	II
1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于密度的聚类.....	2
1.2.2 基于图结构的聚类.....	4
1.2.3 基于采样的聚类.....	4
1.3 研究内容.....	5
1.4 论文组织结构.....	5
2 聚类相似度度量与评价指标.....	7
2.1 相似度度量.....	7
2.1.1 欧氏距离.....	7
2.1.2 余弦相似度.....	7
2.1.3 皮尔逊相关系数.....	8
2.1.4 杰卡德相似系数.....	8
2.2 聚类评价指标.....	8
2.2.1 调整兰德系数.....	8
2.2.2 调整互信息.....	9
2.2.3 Fowlkes-Mallows 指数.....	9
2.2.4 F-measure.....	10
2.3 本章小结.....	10
3 ECAAD 算法.....	11
3.1 问题描述.....	11
3.2 算法流程.....	11
3.3 形状保持采样.....	12
3.4 代表点位置调整.....	14

3.5	凝聚聚类.....	16
3.6	算法时间复杂度分析.....	17
3.7	本章小结.....	17
4	实验分析.....	19
4.1	实验设置.....	19
4.1.1	数据集设置.....	19
4.1.2	参数设置.....	20
4.1.3	对比算法.....	22
4.2	实验结果及分析.....	23
4.2.1	合成数据集实验效果.....	23
4.2.2	算法性能对比.....	24
4.2.3	算法可扩展性对比.....	26
4.3	本章小结.....	27
5	结论.....	28
5.1	工作总结.....	28
5.2	未来展望.....	28
	参考文献.....	30
	致谢.....	33

1 绪论

1.1 研究背景与意义

在人工智能与大数据技术迅猛发展的今天，数据已成为驱动社会进步的核心生产要素。随着5G、物联网和边缘计算的普及，全球数据量正呈指数级增长，其形态也日益复杂化——从传统的结构化数据到高维非结构化的图像、视频、时空轨迹和社交网络数据，数据分布的复杂性和多样性远超传统算法的处理能力。在这一背景下，如何从海量异构数据中高效提取有价值的信息模式，已成为制约智能决策的关键瓶颈。

为了挖掘到对我们有用的信息，数据挖掘技术不断发展。数据挖掘利用算法和统计工具在庞大的数据中自动发掘规律、模式和知识。它结合机器学习、统计学和数据库技术，帮助人类做出更高效的决策。对于本身杂乱无章、没有标签的数据，无监督学习更是解决这类问题的关键工具。

在数据科学领域，聚类分析作为无监督学习的核心方法，其重要性随着数据复杂度的提升而日益凸显。其目标是将数据集中的样本划分为若干个簇，使得同一簇内的样本相似度高，而不同簇间的样本相似度低。在当今时代，聚类算法广泛应用于数据挖掘、工业过程监控、生物信息学、推荐系统等多个领域。在商业领域，聚类助力客户细分、精准营销和推荐系统，显著提升商业价值；在生物医学中，它帮助解析基因数据、识别疾病亚型，推动个性化医疗发展；在智能制造中，聚类算法优化生产流程、检测异常，提高工业效率。此外，随着人工智能和物联网的普及，聚类在图像分割、社交网络分析、多源传感器数据处理等方面展现出不可替代的作用。面对数据多样性和实时性需求的挑战，聚类算法的创新不仅推动了数据科学本身的进步，更成为智慧城市、数字化转型等国家战略的重要技术支撑，其发展对释放数据潜力、赋能产业升级具有深远意义。

传统聚类算法基于球形分布或凸包假设的局限性，促使研究者转向任意形状聚类这一更具普适性的研究方向。现实数据往往呈现出复杂的非线性结构：社交网络中的社区形成不规则拓扑，生物信息数据呈现多密度交织分布，地理信息数据则具有蜿蜒的空间特征。这些特性使得传统的基于距离或密度的聚类方法难以准确捕获数据的真实分布模式。任意形状聚类研究的核心价值在于突破了传统算法的几何约束，通过引入拓扑保持、局部密度自适应等机制，实现了对复杂数据

结构的本质认知。这一研究方向不仅拓展了聚类分析的理论边界，更为处理真实世界中的非结构化数据提供了方法论基础。

任意形状聚类最具代表性的应用之一是地理空间数据分析。例如，在城市计算中，基于位置的服务（LBS）需要将用户的移动轨迹聚类成有意义的区域，以识别热门商圈或交通枢纽。这些数据通常呈现不规则的流形分布，传统的基于距离的聚类方法难以准确划分边界。类似地，在生物医学领域，单细胞RNA测序数据的聚类分析要求算法能够识别细胞亚群的复杂分布模式，而任意形状聚类方法能够更精准地揭示细胞异质性，为疾病诊断和治疗提供关键支持。当前研究的重点已从单纯追求形状识别能力，转向在计算效率、噪声鲁棒性和参数自适应性之间寻求最优平衡，这正是推动该领域持续发展的关键动力。

1.2 国内外研究现状

由于聚类在数据分析领域的重要位置，国内外学者持续投入大量研究精力，在传统聚类算法的基础上不断改进创新，并提出任意形状聚类算法，以处理数据分布不规则的情况。本文研究的主要内容也是面向任意形状数据的高效聚类算法。现有可用于识别任意形状聚类的聚类算法大致分为如下几类介绍：基于密度的聚类、基于图结构的聚类、以及基于采样的聚类。

1.2.1 基于密度的聚类

基于密度的聚类方法通过发现数据空间中样本分布的稠密程度来识别任意形状的簇结构，已成为复杂数据聚类的重要研究方向。这类方法的核心思想是“簇是数据空间中由低密度区域分隔的高密度区域”，相比基于距离或划分的聚类方法，能够更好地处理非凸分布、噪声干扰和异质簇大小等复杂场景。经典的DBSCAN^[1]算法是基于密度聚类算法的杰出代表。它通过定义核心点（ ϵ 邻域内至少包含 $MinPts$ 个样本）、边界点和噪声点，并基于密度直达和密度可达性等概念，巧妙构建起簇结构，从而实现了对非凸分布数据的有效聚类。具体而言，DBSCAN算法框架如算法1所示。

DBSCAN算法的具有显著的优势。首先，算法只有两个关键参数，且无需预先指定聚类数目。其次，它可以发现任意形状的聚类，且对噪声不敏感。算法的缺点在于其计算复杂度较高，在未进行任何优化处理的情况下，时间复杂度为

$O(N^2)$ 。而且当数据集的聚类间相距较大、密度不均匀时，算法的聚类效果会受到明显影响，难以达到理想的聚类精度。

算法 1: DBSCAN 算法框架

输入: 数据集 D ; 邻域半径 ϵ ; 邻域最小点数 $MinPts$

输出: 聚类集合

1. 初始化: 将 D 中所有数据点标记为 `unvisited`
 2. **While** 存在 `unvisited` 的点 p :
 - 标记 p 为 `visited`
 - If** p 的 ϵ -邻域内点数 $\geq MinPts$:
 - 创建新簇 C , 将 p 加入 C
 - 初始化邻域集合 $N = p$ 的 ϵ -邻域内所有点
 - For** p' in N :
 - If** p' 是 `unvisited`:
 - 标记 p' 为 `visited`
 - If** p' 的 ϵ -邻域内点数 $\geq MinPts$:
 - 将 p' 的邻域点加入 N
 - If** p' 不属于任何簇:
 - 将 p' 加入 C
 - Else**
 - 标记 p 为噪声
 3. **return** 所有簇
-

研究者提出了一系列改进方案以解决DBSCAN的局限性。考虑到DBSCAN算法对参数敏感的特性，Ankerst等人提出了OPTICS^[2]算法，使用样本的核心距离和可达距离来展现聚类结构。该算法通过引入可达距离图替代全局密度阈值，生成簇排序以反映不同密度层次的聚类结构，实现了多尺度密度聚类分析。而HDBSCAN^[3]则结合层次聚类的思想处理变密度数据，首先构建基于互达距离的密度分层树，然后通过稳定性分析提取最优聚类结果。该算法的参数依赖性更小，参数调整更方便。

另一种相似的思路是通过识别局部密度极值点来构建聚类。其中，DENCLUE^[4]算法使用核密度估计构建数据点的影响力函数，通过梯度上升法将样本关联到最近的密度吸引子。而Rodriguez和Laio提出的DPC^[5]则根据密度峰值划归附近样本，创新性地引入决策图直观展示聚类中心，其核心假设是簇中心同时具有高局部密度和较大相对距离。VDPC算法^[6]是DPC的改进版本，采用分治策略，在每个密度级别上层层递进得到聚类中心。其余改进版本还有极端聚类方法EC^[7]。类似的，CLUB^[8]通过引入边界检测机制提升噪声鲁棒性，而后续的改

进算法SKM-DPC^[9]则结合核方法和稀疏优化提升了算法在高维数据上的表现。这些密度聚类方法在生物信息学、社交网络分析等领域展现出独特优势。

1.2.2 基于图结构的聚类

基于图结构的聚类方法通过将数据建模为图并利用图划分技术识别簇结构，已成为处理复杂数据分布的重要工具。这类方法的核心思想是将数据点表示为图中的节点，并根据节点间的相似性构建边，最终通过图划分等技术识别数据中的自然分组。

CHAMELEON^[10]算法作为一种典型的基于图的聚类算法，可以自动地进行簇的合并。它将数据转化为 k 近邻图，并利用图划分算法将数据划分为预定义数目的子图；随后，通过动态计算簇间的相对互连度和相对紧密度，合并满足相似性条件的子图实现聚类。CHAMELEON 算法使用动态层次建模，可以高效处理大规模数据集，发现任意形状的聚类，其时间复杂度为 $O(N^2)$ 。但是，CHAMELEON 算法依赖参数设置，对于参数调优的需求较高。

谱聚类算法通过将任意形状的簇嵌入低维空间，使得聚类结构更易于区分，从而完成聚类任务^[11]。然而，由于需要计算特征向量，这类方法通常面临较高的时间和空间复杂度（通常为 $O(N^2)$ 至 $O(N^3)$ ），这限制了其在大规模数据集上的可扩展性。作为代表性的基于图的聚类方法，谱聚类的发展经历了从基础理论到实践优化的完整过程。2001年Jianbo Shi等人提出归一化割（Normalized Cut）^[12]准则，通过优化图分割的归一化损失函数，解决了传统分割方法对不规则簇形状的局限性。之后的研究者通过图稀疏化技术降低谱聚类的计算复杂度，适用于大规模数据^{[13][14]}。经典的谱集成聚类算法SEC通过融合多个基聚类结果构建共识矩阵，并利用谱聚类优化共识划分，提升了算法的鲁棒性和泛化能力。多密度谱聚类（MDSC）^[15]将高斯混合模型的概率密度理论融入算法设计中，能够敏锐捕捉数据分布中的密度差异。

1.2.3 基于采样的聚类

在面对大规模数据集时，基于采样的聚类方法通过减少待处理的样本数量，从而有效降低计算成本。经典的基于采样的聚类算法 CURE^[16]通过随机采样策略选择代表点，并将这些代表点划分为多个小聚类，然后不断合并这些小聚类以得到最终的聚类结果。类似地，IK-means 算法^[17]通过先利用 K-means 算法生成多

个子簇，再根据子簇在超平面上的数据密度和两个子簇之间的最短距离来评估子簇的连通性，进而合并小聚类。

然而，随机采样的策略尽管直观快速，但容易造成不均匀采样，丢失数据集原本的聚类结构。因此，后来的研究人员通过改进采样策略，加强采样点对数据集聚类结构的代表性，从而改善聚类效果。SPARCL^[18]和 ABACUS^[19]算法的采样策略基于密度分布，通过优先选取位于局部密度中心的代表点，能够更合理地反映数据分布情况。然而，当数据存在显著密度差异时，这类方法获取的代表点分布可能出现几何形变，反而可能对后续聚类分析造成干扰。

CLASP^[20]算法使用基于网格划分的方法采样，从数据样本数量超过一定阈值的非空网格中选取代表点。之后通过调整代表点的位置，增强它们的内在关系，使得聚类结果更加易于识别。最后通过基于 k 近邻关系的相似性度量，对采样点进行凝聚聚类得到聚类结果。通过这三个阶段，CLASP 算法实现了高效聚类，但其局限性在于，网格划分采样在高维数据中或消耗大量时间，因此只适用于较低维度的数据集。

1.3 研究内容

在任意形状聚类的流行算法中，已有成熟的算法思路可以适应数据集的复杂形状，但是保证算法的高效与快速仍然是当前研究的重点。本文希望在借鉴流行算法在处理噪声点、动态生成采样点、自适应密度连接等思想的基础上，找到一种能够高效处理任意形状数据的聚类算法。

本文提出的ECAAD算法采用如下的思路：首先从原始数据中提取一组代表性点，较好地保留数据的全局结构，再通过对代表点位置进行调整，使其更合理清晰地反映数据的局部密度分布，最后使用凝聚聚类对优化后的代表点进行合并，并给所有原始数据分配聚类结果。这样，ECAAD算法在代表点选择和位置调整过程中可以充分考虑数据的几何特征和密度分布，从而能够有效识别复杂形状的簇，同时通过采样和优化策略提高计算效率。

1.4 论文组织结构

本文共分为五个章节，具体组织结构如下：

第1章为绪论，主要阐述任意形状聚类研究背景及其在各个领域的重要意义。通过分析目前的国内外研究现状与存在的问题，明确本文的研究内容和创新点。

第2章为相关工作介绍，系统回顾与本文研究相关的关键算法，重点分析这些方法的优势与局限性，同时对评价聚类效果的相关指标进行介绍。

第3章为ECAAD算法设计，详细阐述本文提出的面向任意形状数据的高效聚类算法。算法三个阶段的技术细节通过公式推导等进行说明，并对算法的时间复杂度进行了理论分析。

第4章是实验与结果分析，通过在合成数据集和真实数据集上与主流聚类算法进行比较，验证ECAAD算法的性能。实验设计包括参数选取实验、算法性能对比以及可扩展性测试。实验结果通过聚类精度指标和运行时间进行量化评估，并结合可视化结果展示算法的优势。

第5章为结论部分，总结了本文的工作，并对面向任意形状数据的高效聚类算法的未来研究方向提出展望。

2 聚类相似度度量与评价指标

本章重点介绍聚类问题和 ECAAD 算法中出现的重要概念。对任意形状聚类问题的研究，其核心在于如何准确衡量数据样本间的"相似性"。在聚类分析中，研究者们通常通过计算样本间的相似度数值，并以此为依据判断它们是否应归为同一类别^{[21][22][23]}。本章将首先系统阐述各类相似度度量方法，随后深入探讨聚类效果的评价标准体系。

2.1 相似度度量

在聚类分析中，相似性度量用于量化两个对象之间的相似程度。其本质是建立一个映射关系，将数据对象之间的关系用可计算的数值表示。相似性度量的选择直接决定了样本之间关系建模的准确性，影响聚类算法对数据真实结构的识别能力。因此，在聚类算法的设计中，选择合适的相似性度量是至关重要的。

本节介绍一些常用的相似性度量，包括欧氏距离、余弦相似度、杰卡德相似系数和皮尔逊相关系数。

2.1.1 欧氏距离

欧式距离是距离度量的最基础方法，用于计算 n 维空间中两点的直线距离。给定两点 $x = (x_1, x_2, \dots, x_n)$ 和 $y = (y_1, y_2, \dots, y_n)$ ，其欧氏距离计算公式为：

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (2.1)$$

欧式距离广泛应用于低维数值数据的聚类，如K-means聚类和层次聚类。它的优势在于计算简单、几何意义明确，且符合人们对于“直线距离”的认知。同时，欧氏距离的局限性也很明显：它对特征量纲敏感，需要提前标准化；在高维度数据中其区分度明显下降，容易造成维度灾难；由于平方值的放大效果，欧式距离受离群点影响也较为明显。

2.1.2 余弦相似度

余弦相似度（Cosine）通过计算两个向量夹角的余弦值来衡量它们的相似性，其取值范围为 $[0, 1]$ ，值越大表明相似度越高。给定两个 n 维向量 A 和 B ，其余弦相似度公式为：

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \cdot \|B\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}} \quad (2.2)$$

余弦相似度仅关注向量的方向，适合高维度的稀疏数据，计算速度较快。但由于忽略了向量模长，可能导致信息的丢失。

2.1.3 杰卡德相似系数

杰卡德相似系数（Jaccard Similarity Coefficient）用于衡量两个有限样本集合间的相似性，定义为两集合交集大小和并集大小的比值，其取值范围为[0, 1]，值越大表明相似度越高。给定两个 n 维向量 A 和 B ，其杰卡德相似系数为：

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (2.3)$$

杰卡德相似系数适用于集合或二元特征，常应用于文本分析，比如求两个文档之间的相似程度。

2.1.4 皮尔逊相关系数

皮尔逊相关系数（Pearson Correlation Coefficient）用于衡量两个连续变量之间的线性相关性，定义为协方差和标准差的比值，其值为[-1, 1]。1 表示完全线性正相关，-1 表示完全线性负相关，0 表示无线性相关性。皮尔逊相关系数的计算公式为：

$$\gamma_{X,Y} = \frac{\text{cov}(X,Y)}{\sigma_X \sigma_Y} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (2.4)$$

皮尔逊相关系数的一个重要特性是尺度与位置不变性，即对变量 X 和 Y 进行平移或者缩放变换时，相关系数保持不变。由此可得，与余弦相似度类似，皮尔逊相关系数忽略向量模长，仅关注向量的方向。

2.2 聚类评价指标

在聚类分析中，聚类的输出结果需要用合理的方式进行量化评估，以判断聚类算法的精确度与可靠性。本节系统梳理与本研究相关的聚类评价指标，包括调整兰德系数、调整互信息、Fowlkes-Mallows 指数以及 F-measure。

2.2.1 调整兰德系数

调整兰德系数（Adjusted Rand Index, ARI）是兰德系数（Rand Index, RI）的改进版本，用于量化聚类结果与真实标签之间的一致性程度^[24]。ARI 通过统计聚类结果中样本对的划分情况，评估其与真实标签的相似性。其值域为[-1, 1]，

其中 1 表示完全匹配，0 表示随机划分，负值则表明聚类结果与真实标签存在显著差异。计算公式如下：

$$ARI = \frac{RI - E(RI)}{\max(RI) - E(RI)} \quad (2.5)$$

其中，RI 的计算基于样本对的划分一致性。用 a 表示在聚类结果和真实标签中均被划分到同一簇的样本对数，b 表示均被划分到不同簇的样本对数，c 和 d 分别表示划分不一致的样本对数，则有 RI 的计算公式：

$$RI = \frac{a+b}{a+b+c+d} \quad (2.6)$$

2.2.2 调整互信息

互信息（Mutual Information, MI）衡量两个聚类结果的共享信息量，其计算方式为：

$$MI(U, V) = \sum_{i=1}^K \sum_{j=1}^L P(U_i, V_j) \log \frac{P(U_i, V_j)}{P(U_i)P(V_j)} \quad (2.7)$$

然而，原始 MI 受聚类数目和样本量影响。因此，实际常用两种 MI 的改进版本——调整互信息和标准互信息作为聚类评价指标：

调整互信息（Adjusted Mutual Information, AMI）通过计算聚类结果与真实标签之间的互信息，并对随机划分的期望值进行校正。AMI 的值域为[0, 1]，1 表示完全一致，0 表示随机划分。其计算公式为：

$$AMI = \frac{MI(U, V) - E[MI(U, V)]}{\max(H(U), H(V)) - E[MI(U, V)]} \quad (2.7)$$

其中， $MI(U, V)$ 是聚类结果 U 和真实标签 V 之间的互信息， $H(U)$ 和 $H(V)$ 分别是 U 和 V 的熵。

标准互信息（Normalized Mutual Information, NMI）则通过归一化互信息^[25]，使其值域限定为[0, 1]。其计算公式为：

$$NMI(U, V) = \frac{2 * MI(U, V)}{H(U) + H(V)} \quad (2.8)$$

2.2.3 Fowlkes-Mallows 指数

FMI（Fowlkes-Mallows Index）是一种用于评估两个聚类结果相似性的指标，特别适用于有监督聚类验证或不同聚类算法结果的一致性比较^[26]。它通过衡量点对的分组一致性来量化聚类质量，取值范围为[0, 1]，值越接近 1 表示聚类结果越一致。

FMI 基于两个点的划分一致性计算：

真正例（TP）：两个点在真实标签和预测标签中属于同一簇。

假正例（FP）：两个点在预测标签中同一簇，但在真实标签中不同簇。

假反例（FN）：两个点在真实标签中同一簇，但在预测标签中不同簇。

FMI 的计算公式为：

$$FMI = \frac{TP}{\sqrt{(TP+FP) \cdot (TP+FN)}} \quad (2.9)$$

2.2.4 F-measure

精确率(Precision)用来表示在所有被模型预测为正类的样本中，真正属于正类的比例，即 $P = TP / (TP + FP)$ 。

召回率(Recall)用来表示在所有实际为正类的样本中，被模型正确预测为正类的比例，即 $R = TP / (TP + FN)$ 。

F-measure（也称为 F-Score）是统计学中用于衡量分类模型准确性的重要指标，它综合了精确率和召回率的表现，计算公式如下：

$$F_{\beta} = \frac{(\beta^2 + 1)PR}{\beta^2 \cdot P + R} \quad (2.10)$$

参数 β 的值为 1 时，是最常用的 F1-Measure：

$$F_1 = \frac{2PR}{P+R} \quad (2.11)$$

2.3 本章小结

本章系统性介绍了任意形状距离研究中的相关概念。首先介绍四种常用的相似性度量，给出其定义以及计算公式，并分析每个相似性度量的适用情况。然后介绍了四种常用的聚类评价指标，分别是调整兰德系数、调整互信息以及 Fowlkes-Mallows 指数、F-measure，使得算法设计与实验得到充分的理论补充。

3 ECAAD算法

为实现面向任意形状数据的高效聚类，本文提出了ECAAD算法（Efficient Clustering Algorithm for Arbitrary-Shaped Data）。本章中首先对任意形状聚类这一问题进行了描述，之后介绍了ECAAD算法的实现流程，并详细阐述每个阶段的过程，辅助以相关定理的数学证明，最后对该算法进行了总结。

3.1 问题描述

任意形状聚类问题的核心任务如下：给定一个包含 N 个数据样本的数据集 $D = \{x_1, x_2, \dots, x_n\}$ ，其中每个样本 x_i 是 d 维特征空间的一个点。聚类目标是将这些样本划分到 N_c 个互不相交的簇中，并输出对应的聚类标签集合 $Label = \{l_1, l_2, \dots, l_n\}$ ， $l_i \in \{1, 2, \dots, N_c\}$ 。同一聚类内的数据样本之间需要具有较高的相似性，而不同聚类之间的数据样本要具有较大的差异性。

相较于传统的聚类问题，任意形状聚类问题中的数据簇可能呈现非凸、多连通、环形或流形等复杂的几何结构。因此，传统的聚类算法并不适用于解决任意形状聚类问题。

3.2 算法流程

为解决传统聚类算法在处理任意形状数据集时的局限性，本文提出的ECAAD算法通过以下步骤实现有效聚类：首先采用形状保持采样方法从原始数据集中提取代表点，以捕捉数据的整体分布特征；随后构建影响力矩阵对这些代表点的位置进行优化调整，使其能够更准确地反映原始数据的空间分布结构；最后对调整后的代表点进行凝聚聚类，并将聚类结果映射回原始数据集，从而实现对任意形状数据的高效聚类。

ECAAD 算法的伪代码如下。

算法 2 ECAAD 算法

输入：数据集 P ，聚类个数 N_c ，代表点个数 N_r ， k 近邻参数 k ，迭代次数 N_{iter}

输出：数据集 P 中各数据样本的类别

1. 对预处理后的数据进行形状保持采样，得到 N_r 个采样点；
 2. 对采样点进行 K-means 运算，得到最终代表点；计算影响力矩阵，迭代调整代表点位置，直到迭代次数达到 N_{iter} ；
 3. 进行第二次离群点去除后，对剩余代表点进行凝聚聚类，得到 N_c 个聚类；为离群点以及原始数据分配聚类标签。
-

ECAAD 算法的关键过程如图 3.1 所示：




图3.1 算法关键过程图

3.3 形状保持采样

为在数据集上取得连续均匀的采样，ECAAD 算法选择使用形状保持采样的方法。采样阶段包含数据预处理与渐进式最远点采样两个工作。

在数据预处理部分，最关键的步骤为将标准化后的数据进行离群点去除，以保证算法的准确性和鲁棒性。离群点常常位于各个簇的过渡部分或者远离主体区域，无法代表某个有效的聚类。如果对离群点不加处理，选择其为代表点，将影响到聚类结果的准确性，导致聚类边界模糊或者形成额外的无意义聚类。本文使用改进的局部离群因子检测算法^[27]（LOF+）来去除离群点，该方法可以快速进行离群点检测，且时间复杂度接近线性。

我们假设 P 为去除离群点之后的数据集，样本数量记为 $|P|$ 。数据集的维度为 d ，样本 p_i 坐标为 $X_i = (x_{i,1}, x_{i,2}, \dots, x_{i,d})$ 。进行了 t 轮采样之后，记已经选出的采样点为 R_t 、剩余采样点为 C_t ，则满足 $C_t = P \setminus R_t$ 。定义 $d(p_i, p_j)$ 为样本中两元素 p_i 和 p_j 的欧式距离。在 $t-1$ 轮采样完成后，所有候选点与其最近邻采样点构成的集合为 $DS_t = \{ \min_{p_j \in R_{t-1}} d(p_i, p_j) | p_i \in C_{t-1} \}$ 。

初始状态下，采样点集合 R_0 为空，候选点集合 C_0 为去除掉离群点的完整数据集 P 。每轮采样时，我们都要从 C_t 中选择一个样本转移到 R_t 。首先计算出数据集 P

的几何中心坐标 X_{mean} ，计算方式为每个维度下所有数据点的最大值和最小值取平均值。首个采样点选择距离几何中心 X_{mean} 最近的样本，后续采样点选取时，先要找到其在当前采样集 R_t 中的最近邻点，即 $p_i^{nearest} = \underset{p_j \in R_t}{argmin} d(p_i, p_j)$ 。

然后计算所有候选点与其最近邻采样点间的距离，并选择距离最大的采样点作为下一轮采样点。采样点的选取公式如(3.1)所示，其约束条件为 $1 \leq t \leq (N_r - 1)$ ， N_r 为预设的采样点个数：

$$r_{t+1} = \underset{p_i \in C_t}{argmax} d(p_i, p_i^{nearest}) \quad (3.1)$$

随着采样过程的进行，新增采样点与已有采样点之间的最小距离会逐渐减小并趋于稳定。为了量化这一趋势，定义以下收敛判断机制：

设 $d_{min}(t)$ 为第 t 次迭代时新增采样点与原有采样点集合的最小距离，我们这里计算最近5次迭代的最小移动距离的平均值 $avg_{d_{min}}$ ，即 $avg_{d_{min}} = \frac{d_{min}(t) + d_{min}(t-1) + d_{min}(t-2) + d_{min}(t-3) + d_{min}(t-4)}{5}$ 。

若连续多次满足相对误差条件，则认为最小距离已稳定，采样点分布达到目标密度，由此避免噪声或局部波动导致的误判。设 ε 为预设的阈值，收敛判定条件如公式（3.2）所示：

$$\frac{|d_{min}(t) - avg_{d_{min}}|}{avg_{d_{min}}} < \varepsilon \quad (3.2)$$

为直观表示 ECAAD 算法使用的形状保持采样较随机采样方法的优势，本文进行实验对比了两种采样方法，效果分别如图 3.2 和 3.3 所示。结果表明，随机采样更容易导致代表点分布不均，部分区域过于集中而其他区域则过于分散；相比之下，形状保持采样能够使代表点更均匀、连续覆盖原始数据的聚类结构，采样效果更好。




图3.2 形状保持采样效果




图3.3 随机采样效果

3.4 代表点位置调整

完成上述采样过程后，采样点在数据集中均匀分布，我们下一步的任务就是调整采样点位置，使其更接近局部密度中心，更合理地反映局部结构，提高后续分析的准确性。首先，我们将采样点作为初始聚类中心，使用 K-means 算法对数据进行凸分解，即把数据划分为若干个凸形状的簇。随后，在每个簇中寻找距离当前簇中心最近的数据点，并用这些点来更新采样点的位置。

为系统性地调整代表点空间分布，本文提出了一种基于代表点同质性的迭代优化策略。该方法的核心思想是通过量化评估代表点之间的同质性特征，并基于评估结果动态调整代表点位置，使得具有高同质性的代表点（即更可能属于同一类别的代表点）在空间上逐渐聚集，同时降低不同类别代表点之间的空间重叠，从而在可视化呈现上形成更加清晰的聚类边界。

在技术实现层面，ECAAD 算法首先构建了一个基于 k 近邻的代表点关系图模型。该图模型以所有代表点作为顶点，通过 k 近邻准则建立顶点之间的边连接，形成一个能够反映代表点局部空间关系的网络结构。基于该图模型，ECAAD 算法通过构建一个影响力矩阵，描述代表点之间在多维特征空间中的相似程度，影响力矩阵的计算公式如下：

$$W_{ij} = \begin{cases} \frac{\min\{ld_i, ld_j\}}{\max\{ld_i, ld_j\}} \cdot \frac{|L_{ij}| + |L_{ji}|}{|L_i| + |L_j|} \cdot G_{ij}, & y_i \text{ 和 } y_j \text{ 连通} \\ 0, & otherwise \end{cases} \quad (3.3)$$

公式（3.3）中给出了影响力矩阵的计算方法，即从三个维度考量代表点之间的同质性：密度相似性、接触面重合度、空间邻近性度量。其中，第一个因数通过比较不同聚类的密度比值，可以准确评估两个聚类在分布密度上的相似程度， ld_i 为小聚类 L_i 的局部密度，定义为 $ld_i = \frac{|L_i|}{\sum_{x_t \in L_i} \|y_i - x_t\|}$ 。第二个因数能够有效反映两个聚类在边界区域的混合程度， $L_{ij} = \{x \in L_i \mid \|x_i - y_j\| \leq \mu_{ij}\}$ 为两个代表点 x_i 与 y_j 的相互影响区域。第三个因数为改进的高斯核函数，用于评估代表点之间的相对距离关系。计算方式如公式 3.4 所示：

$$G_{ij} = e^{(-\frac{\|y_i - y_j\|^2}{\sigma_i^2 + \sigma_j^2})} \quad (3.4)$$

其中， $\sigma_i = \frac{1}{k} \sum_{x_i \in kNN_{y_i}} \|x_i - y_i\|$ 为局部尺度参数，通过引入局部邻域标准差，

有效消除了数据尺度差异的影响。

得到影响力矩阵之后，将其进行归一化为矩阵 W^* 用于迭代调整代表点位置。每次迭代的位置更新公式为：

$$y_i^{t+1} = \sum_j W_{ij}^* * y_j^t \quad (3.5)$$

这样的位移更新方式随着迭代次数的增加不断收敛，代表点的位移量不断减小，下面我们对此进行证明：

根据（3.5）的位置更新公式可得 $S^{(t)} = W^* \cdot S^{(t-1)}, \forall t \geq 1$ ，则第 t 轮迭代代表点的位移量矩阵为 $Z^{(t+1)} = W^* S^{(t)} - S^{(t)}$

$$\begin{aligned} &= W^* W^* S^{(t-1)} - W^* S^{(t-1)} \\ &= W^* (W^* S^{(t-1)} - S^{(t-1)}) = W^* Z^{(t)} \end{aligned}$$

即 $Z^{(t+1)} = \sum_{i=1}^{|S|} W_{ij}^* Z_j^{(t)}$ ，其中 $Z_j^{(t)}$ 表示 $Z^{(t)}$ 矩阵的第 j 行。

设 $V^{(t)}$ 是 $Z_j^{(t)}, Z_j^{(t)}, \dots, Z_j^{(t)}$ 组成的最小凸区间（或凸包、凸多面体），则

$$V^{(t)} = \left\{ \left\{ \lambda_1 Z_1^{(t)} + \dots + \lambda_{|S|} Z_{|S|}^{(t)} \mid \lambda_i \geq 0, i = 1, 2, \dots, |S|, \sum_{i=1}^{|S|} \lambda_i = 1 \right\} \right\}$$

令 $|Z^{(t)}|_M$ 表示位移矩阵 $Z^{(t)}$ 的最大位移距离，则有

$$|Z^{(t)}|_M = \max\{\|Z_1^{(t)}\|, \dots, \|Z_{|S|}^{(t)}\|\}$$

以下定理从理论上保证 $V^{(t)}$ 与 $|Z^{(t)}|_M$ 是随着位移次数 t 的增加呈递减趋势的。

定理 1: 当 $t=1, 2, 3, \dots$ 时，有 $V^{(t+1)} \subseteq V^t$ 和 $|Z^{(t+1)}|_M \leq |Z^{(t)}|_M$ 。如果所有 $i = 1, \dots, |S|$ ， $W_{ij}^* < 1$ ，则 $V^{(t+1)} \subset V^t$ 和 $|Z^{(t+1)}|_M < |Z^{(t)}|_M$ 。

证明：当 $i, 1 \leq i \leq |S|$ ，有 $Z_i^{(t+1)} = \sum_{j=1}^{|S|} W_{ij}^* Z_j^{(t)}$

而且 $\sum_{j=1}^{|S|} W_{ij}^* = 1, W_{ij}^* \geq 0$ ，有 $Z_i^{(t+1)} \in V^t$ 和

$$\|Z_i^{(t+1)}\| = \left\| \sum_{j=1}^{|S|} W_{ij}^* Z_j^{(t)} \right\| \leq \left\| \sum_{j=1}^{|S|} W_{ij}^* |Z^{(t)}|_M \right\| = |Z^{(t)}|_M$$

即，对于任何 $1 \leq i \leq |S|$ ，有 $Z_i^{(t+1)} \in V^t$ 和 $\|Z_i^{(t+1)}\| \leq |Z^{(t)}|_M$ ，然后 $V^{(t+1)} \subseteq V^t$ 和 $|Z^{(t+1)}|_M \leq |Z^{(t)}|_M$ 。

接下来，对于所有 $i = 1, \dots, |S|$ ， $W_{ii}^* < 1$ 。对于任何固定 $i, 1 \leq i \leq |S|$ ，

因为 $W_{ii}^* < 1$ ，存在一些 $k \neq i$, $1 \leq k \leq |S|$, $W_{ik}^* > 0$ ，然后

$$\begin{aligned} \|Z_i^{(t+1)}\| &= \left\| \sum_{j=1}^{|S|} W_{ij}^* Z_i^{(t)} \right\| \\ &\leq W_{ii}^* \|Z_i^{(t)}\| + W_{ik}^* \|Z_k^{(t)}\| \\ &\leq (W_{ii}^* + W_{ik}^*) \max\{\|Z_i^{(t)}\|, \|Z_k^{(t)}\|\} \end{aligned}$$

因为 $Z_i^{(t)} \neq Z_k^{(t)}$ ，上述两个不等式中的等号不能同时成立，因此

$$\begin{aligned} \|W_{ii}^* Z_i^{(t)} + W_{ik}^* Z_k^{(t)}\| &< (W_{ii}^* + W_{ik}^*) \max\{\|Z_i^{(t)}\|, \|Z_k^{(t)}\|\} \\ &\leq (W_{ii}^* + W_{ik}^*) |Z^{(t)}|_M \end{aligned}$$

因此得出

$$\begin{aligned} \|Z_i^{(t+1)}\| &\leq \|W_{ii}^* Z_i^{(t)} + W_{ik}^* Z_k^{(t)}\| + \sum_{j \neq i, k} W_{ij}^* |Z^{(t)}|_M \\ &< (W_{ii}^* + W_{ik}^*) |Z^{(t)}|_M + \sum_{j \neq i, k} W_{ij}^* |Z^{(t)}|_M = |Z^{(t)}|_M \end{aligned}$$

即， $|Z^{(t+1)}|_M < |Z^{(t)}|_M$ 。

因为 $V^{(t+1)} \subseteq V^t$ ，而且因为 $|Z^{(t+1)}|_M < |Z^{(t)}|_M$ ，得到 $V^{(t+1)} \neq V^t$ ，有 $V^{(t+1)} \subset V^t$ 。

定理得证。

由上述证明可见，由于数据集中存在凸包，每次代表点的位移量都存在上限，且上限随着迭代次数增加而减小。故代表点的位移是收敛的。

3.5 凝聚聚类

在完成代表点位置调整后，具有相似特征的代表点会自发形成聚集分布。此时，这种空间分布特性使得代表点之间的距离能够有效反映原始样本的聚类结构关系，从而为识别复杂分布形态（包括非凸形、多密度等任意形状的簇）提供了重要基础。基于此，本算法使用一种基于最小类间距的凝聚聚类算法，实现流程为：

- （1）初始化阶段。将每个代表点视为一个独立的簇。
- （2）迭代合并阶段。重复执行以下操作：计算当前所有簇两两之间的最小距离；选择距离最近的两个簇进行合并，形成新的簇。

这一过程持续迭代,直到剩余簇的数量满足预设的聚类数目 N_c 。聚类完成后,每个代表点的聚类标签会直接赋给其对应的原始数据样本,实现全局数据的类别划分。对于初始采样中被标记为离群点的数据,将其分配到距离最近的样本所属的聚类中,确保无遗漏分类。通过以上步骤,本文最终实现了对目标数据集中所有原始样本的聚类操作。

3.6 算法时间复杂度分析

我们分三个阶段来分析ECAAD算法的时间复杂度:

(1) 形状保持采样阶段。离群点去除部分使用的快速离群点检测算法的时间复杂度为 $O(N)$,其中 N 为原始数据集的大小。初始聚类中心使用连续均匀采样得到,耗时 $O(N_r \cdot N)$,其中 N_r 为代表点个数。接着使用 K-means算法优化代表点集合,同样消耗 $O(N_r \cdot N)$ 的时间。

(2) 代表点位置调整阶段。首先计算代表点间的 k 近邻关系,其时间复杂度为 $O(N_r^2)$ 。迭代调整代表点位置的过程耗时 $O(N_{iter} \cdot N_r \cdot k)$,其中 N_{iter} 为迭代次数(满足 $N_{iter} \ll N_r, k \ll N_r$)。

(3) 凝聚聚类阶段。传统的凝聚聚类时间复杂度为 $O(N_r^3)$,但本文算法实现时采用了堆结构优化最近邻距离计算,时间复杂度为 $O(N_r^2 \log N_r)$ 。

综上所述, ECAAD算法的总体时间复杂度为 $O(N_r \cdot N + N_r^2 \log N_r)$,具有较高的计算效率。

3.7 本章小结

本章首先对本文提出的任意形状聚类算法问题给出了形式化定义,然后介绍了ECAAD算法的流程以及详细技术实现步骤。ECAAD算法通过三个阶段的核心流程,有效解决了传统聚类方法在处理复杂形状数据时面临的计算效率低和聚类精度不足的问题。

首先, ECAAD算法对原始数据集进行离群点去除的操作,采用渐进式最远点的采样策略进行形状保持采样,从而从原始数据中均匀提取具有代表性的采样点并保留原始数据的全局分布特征。接着,算法通过构建影响力矩阵和迭代优化机制,动态调整代表点的位置,使其更准确地反映局部密度分布。该过程结合空

间邻近性、簇间接触面和密度相似性等多维评估，提升了代表点对复杂数据结构的表征能力。同时，本章还对迭代调整代表点这一过程的收敛性进行了理论证明。最后，ECAAD算法使用基于最小类间距的凝聚聚类对调整后的代表点进行合并，生成最终的聚类结果。这一阶段充分利用了代表点的空间分布特性，能够高效识别任意形状的簇结构，并将结果映射到原始数据。

本章还对ECAAD算法的时间复杂度进行了分析，得到算法总时间复杂度为 $O(N_r \cdot N + N_r^2 \log N_r)$ ，说明该方法具有良好的运行效率。

4 实验与分析

本章从实验的角度对算法的实用性进行验证，首先介绍了实验相关设置，包括实验所使用的数据集与实验环境，然后分别在真实数据集和人工数据集上验证 ECAAD 算法的性能。本章中，通过调整停止采样阈值 ϵ 、 k 近邻中的 k 值、迭代次数 N_{iter} 来选取效果最好的参数进行后续实验，接着在人工数据集上可视化 ECAAD 算法的聚类效果。然后在合成数据集上，对比验证 ECAAD 算法与当前 7 个代表性主流算法的性能与可扩展性，最后在本章结尾对本文的 ECAAD 算法性能进行总结与分析。

4.1 实验设置

4.1.1 数据集设置

全面验证算法的性能，本文使用真实数据集以及合成数据集来进行不同的性能测试。如表4.1所示，真实数据集DS1.1~DS1.5使用了5个来自UCI机器学习仓库的数据集，这些数据集在机器学习领域广泛应用且各具特点，分别为Image Segmentation、Landsat Satellite、Dry Bean Dataset、Pen Digits和Letter Recognition，以验证实际情况算法的应用性能。

表 4.1 UCI 数据集

数据集	数据集名称	样本个数	维度	类别
DS1.1	Image Segmentation	2310	19	7
DS1.2	Landsat Satellite	6435	36	6
DS1.3	Dry Bean Dataset	13611	16	7
DS1.4	Pen Digits	10992	16	10
DS1.5	Letter Recognition	20000	16	26

人工数据集如表4.2所示，由Python生成。DS2.1和D2.2为二维数据集，数据点规模分别为4000和8000。瑞士卷数据集DS2.3的维度为3，是非线性降维中经典的流形结构，划分为3个聚类。

表 4.2 人工数据集

数据集	样本个数	维度	类别
DS2.1	4000	2	9
DS2.2	8000	2	6
DS2.3	20000	3	3

为了更全面地验证所提算法在处理高维复杂形状聚类任务中的适应性，本研究使用SynDECA数据生成工具构建了两组具有不同特征的测试数据集（分别命名为DS3.1~DS3.7和DS4.1~DS4.7）。其中，第一组数据集DS3.1~DS3.7具有统一的8维特征空间，样本规模从5000到35000不等，旨在考察算法在不同数据量级下的表现；第二组数据集DS4.1~DS4.7则保持12000个样本的固定规模，特征维度分布在8到56之间，专门用于测试算法对高维数据的处理能力。

本文全部实验在统一的实验环境下进行，以保持实验结果的稳定与可重复性。硬件环境为：Intel Xeon E5-2678 v3 @ 2.50GHz处理器和128GB内存。软件环境为：Windows 10操作系统、Python 3.8编程语言，使用PyCharm作为集成开发环境开展实验。

4.1.2 参数设置

在ECAAD算法的设计与实现过程中，参数设置对算法的性能和聚类效果具有决定性影响。合理的参数选择不仅能够提升算法的运行效率，还能确保聚类结果在不同数据集上的鲁棒性和准确性。这一部分，我们通过在真实数据集DS1.1~DS1.5上使用不同的参数进行实验，观察参数变化对本文算法聚类效果的影响（用NMI表示）。

代表点个数 N_r ：ECAAD算法自动选取一系列数据点作为K-means算法的初始聚类中心。由公式（3.2）可得，代表点的个数与采样停止阈值 ϵ 密切相关。如图4.1所示，通过比对不同停止阈值下的NMI发现，当 ϵ 的值到达0.0005时，算法的准确率接近峰值并保持稳定。当 ϵ 取更小值时，聚类结果无明显改善，且需要消耗更多的计算时间。基于这一结果，后续实验将 $\epsilon=0.0005$ 设置为采样停止条件。




图4.1 ϵ 值对聚类结果的影响

表 4.3 展示了在该采样停止条件下不同数据集代表点数量和总样本数的比值，即数据集的收缩比例 N_r/N 。

表 4.3 数据集收缩比例

数据集	数据集样本个数 N	代表点个数 N_r	收缩比例
DS1.1	2310	324	0.140
DS1.2	6435	179	0.028
DS1.3	13611	347	0.025
DS1.4	10992	219	0.020
DS1.5	20000	960	0.048

k 值：本文在使用 K-means 算法选取代表点后，要通过代表点的 k 近邻关系来迭代调整代表点位置。因此，我们需要选取合适的 k 值来保证合理的近邻关系。可以看到，随着 k 值的增大，在各个数据集上的聚类效果（NMI）整体出现先上升后下降的趋势。当 k 值取 4 时，算法未能充分利用采样点的近邻关系，导致聚类效果较差。当 k 值取 6 时，数据集获得最好的聚类效果。当 k 值继续增大时，增加了在不同聚类中寻找近邻的风险，造成聚类效果明显下降。因此，本文后续部分均选取 k 值为 6 进行实验。




图4.2 k 值对聚类结果的影响

迭代次数 N_{iter} ：对代表点进行位置调整时，迭代次数 N_{iter} 与最终效果密切相关。实验发现，在迭代次数达到 20 之后，多条曲线（如 DS1.3、DS1.5 等）的 NMI 值趋于稳定，表明模型性能已接近收敛状态。继续增加迭代次数（如从 20 到 40）对 NMI 的提升非常有限，甚至部分曲线出现小幅波动或下降（DS1.2、DS1.4），出现过拟合的风险，说明模型在 20 次迭代后已基本达到最优性能。故

后续实验选择在迭代次数 N_{iter} 为 20 的条件下进行。




图4.3 迭代次数对聚类结果的影响

4.1.3 对比算法

为了直观展示本文ECAAD算法的优势，本章将其与几种代表性聚类算法进行性能比较，包括基于图的方法Chameleon和MDSC、基于密度的方法DBSCAN、EC和VDPC、基于采样的方法CLASP和IK-means。

- 1) Chameleon 算法^[10]: 该算法通过动态调整聚类过程中的相似性度量来发现任意形状的簇。它首先通过 k -近邻图划分数数据集，识别初始的子簇，然后通过分析子簇间的连通性和内部密度动态合并子簇，适应不同数据分布的特性。
- 2) MDSC 算法^[15]: 该算法是面向高维数据的聚类算法，通过构建加权图来捕获数据点在不同子空间中的密度分布特性。它能够处理多密度和高维数据问题，并通过图分割来识别具有不同密度和分布的簇。
- 3) DBSCAN 算法^[1]: 其核心思想为通过邻域半径 ϵ 和最小点数 $MinPts$ 定义核心点，连接密度可达点形成簇。它能够识别任意形状的簇，且对异常点具有鲁棒性。
- 4) EC 算法^[7]: 谱聚类算法利用拉普拉斯矩阵特征向量对数据图进行谱分解，再对低维特征进行 K-means 聚类。该算法适合稀疏和非凸分布，有较强的理论保障。
- 5) VDPC 算法^[6]: 该算法结合局部密度 ρ 和最小距离 δ 自动识别簇中心，以可视化工具为辅助，首先选择密度峰值作为簇的中心，然后将其余点分

配到最近的中心，适用于发现密度分布差异大的簇。

- 6) CLASP 算法^[20]: 通过迭代采样数据点子集，基于局部密度构建微簇，再合并微簇成最终聚类。它适合大规模数据集，可以快速找到最优的聚类方案，同时降低计算复杂度。
- 7) IK-means 算法^[17]: IK-means 是一种改进的 K-means 算法，其核心思想为动态调整簇中心数量，通过增量学习适应数据分布变化。它减少了传统 K-means 对初始点敏感的问题，同时加速了算法的收敛。

4.2 实验结果及分析

为了验证ECAAD算法的效果，本部分的实验从聚类能力、性能优势、可扩展性三个维度展开，通过图像与表格数据直观展示ECAAD算法的优势。

4.2.1 合成数据集实验效果

为了验证本文提出的 ECAAD 算法在处理任意形状数据聚类任务中的性能表现，本节通过可视化实验展示了该算法在三个人工合成数据集上的聚类效果，如图 4.4、图 4.5、图 4.6 所示。从实验结果可以清晰地观察到，ECAAD 算法不仅能够准确识别数据集中存在的复杂分布模式，还能有效地将具有任意几何形态的数据点集划分成若干具有明确语义边界的聚类簇。这一实验结论充分证明了该算法在处理非凸、非球形等复杂数据结构时具有显著优势。




图4.4 算法在DS2.1上的聚类结果




图4.5 算法在DS2.2上的聚类结果




图4.6 算法在DS2.3上的聚类结果

4.2.2 算法性能对比

为验证 ECAAD 算法相较于其他算法的优势，本小节使用 4.1.3 所提到的 7 种主流算法，在 UCI 标准数据集上进行对比实验。在实验参数设置上，针对采样类方法，我们通过调整其采样比例使其与本研究采用的采样策略保持一致；对于参数敏感的密度聚类方法，实验通过网格搜索选取了多组参数组合，最终报告其在最优参数配置下的性能表现，以确保对比实验的公平性和可靠性。

各个算法的运行时间以及聚类精度如表 4.4 和表 4.5 所示。

表 4.4 各算法运行时间对比(秒)

数据集	DS1.1	DS1.2	DS1.3	DS1.4	DS1.5
Chameleon	0.227	0.749	2.056	45.361	1103.581
MDSC	0.201	1.480	10.648	155.918	1301.025
DBSCAN	0.196	1.258	1.369	1.610	14.511
EC	0.171	0.766	2.651	6.184	20.580
VDPC	0.168	0.578	2.396	9.320	63.193
CLASP	0.152	0.590	1.540	4.749	55.647
IK-means	0.296	0.863	1.364	2.206	10.285
ECAAD	0.144	0.493	1.182	1.264	9.392

表 4.5 各算法性能比较

数据集		算法							
		Chameleon	MDSC	DBSCAN	EC	VDPC	CLASP	IK-means	ECAAD
DS1.1	Acc	0.325	0.510	0.417	0.512	0.501	0.476	0.498	0.532
	ARI	0.122	0.210	0.233	0.201	0.264	0.330	0.375	0.395
	AMI	0.348	0.531	0.495	0.482	0.437	0.534	0.540	0.558
	NMI	0.349	0.534	0.497	0.482	0.439	0.535	0.541	0.560
DS1.2	Acc	0.344	0.607	0.530	0.627	0.580	0.624	0.638	0.726
	ARI	0.197	0.493	0.430	0.374	0.342	0.481	0.573	0.588
	AMI	0.289	0.616	0.554	0.533	0.548	0.439	0.615	0.639
	NMI	0.290	0.617	0.556	0.535	0.549	0.439	0.617	0.639
DS1.3	Acc	0.636	0.550	0.398	0.574	0.619	0.736	0.721	0.748
	ARI	0.454	0.340	0.134	0.410	0.395	0.412	0.585	0.604
	AMI	0.541	0.523	0.310	0.527	0.554	0.564	0.610	0.738
	NMI	0.542	0.524	0.311	0.529	0.555	0.597	0.612	0.738
DS1.4	Acc	0.324	0.340	0.326	0.481	0.514	0.529	0.530	0.534
	ARI	0.200	0.121	0.058	0.378	0.382	0.369	0.343	0.401
	AMI	0.425	0.332	0.225	0.530	0.527	0.441	0.538	0.563
	NMI	0.425	0.332	0.227	0.530	0.527	0.442	0.539	0.563
DS1.5	Acc	0.193	0.173	0.138	0.209	0.258	0.122	0.225	0.233
	ARI	0.135	0.027	0.221	0.041	0.196	0.155	0.210	0.045
	AMI	0.383	0.322	0.252	0.255	0.388	0.407	0.399	0.421
	NMI	0.386	0.325	0.254	0.257	0.389	0.410	0.413	0.425

从运行时间方面来看，ECAAD 算法在所有测试数据集上均表现出最优的计算效率。具体而言：在小规模数据集（如 DS1.1）上，ECAAD 的运行时间与 VDPC 及 CLASP 接近，仍优于其他方法；随着数据规模增大，ECAAD 的计算耗时显著低于 Chameleon 和 MDSC 等传统方法，同时相比基于密度的聚类（如 DBSCAN）和基于采样的聚类（如 CLASP）仍具有明显优势。这一结果验证了 ECAAD 算

法在计算速度上的优越性，尤其是在处理大规模数据时，其时间效率的提升更为显著。

从聚类精度方面来看，本文提出的 ECAAD 算法在准确率（Acc）、调整兰德系数（ARI）、调整互信息（AMI）和标准化互信息（NMI）等核心指标上均取得最优表现，且随着数据规模和复杂度的增加，其性能优势更为突出。

4.2.3 算法可扩展性对比

为考察算法处理大规模数据的能力，本研究在 7 个同维度不同规模的数据集（DS3.1~DS3.7，样本量为 5000~35000），对 ECAAD 算法与 4.1.3 中的主流算法进行了对比测试。如图 4.7 中结果显示，随着数据规模的扩大，所有对比算法的运行时间均呈现上升趋势。值得注意的是，ECAAD 算法与基于采样策略的 CLASP 和 IK-means 方法展现出相似的时间复杂度增长曲线，但在整个测试过程中，ECAAD 始终保持着更优的计算效率优势。

针对高维数据处理需求，我们在 7 个同规模不同维度的数据集（DS4.1~DS4.7，维度为 8~56）上进行了对比实验。图 4.8 的实验数据表明，随着特征维度的提升，各算法的计算开销均有所增加。在此情况下，ECAAD 算法表现出良好的维度适应能力，其运行效率在所有测试维度下均优于其他对比方法。尤其是当处理更高维度的数据时，ECAAD 算法的性能优势更加显著，这充分证明了其在较高维数据分析任务中的实用价值。




图4.7 不同样本数量的可扩展性对比




图4.8 不同样本维度的可扩展性对比

4.3 本章小结

本章主要通过系统的实验设计，从多个角度验证了 ECAAD 算法在任意形状聚类任务中的性能表现。由于算法性能与参数设置密切相关，我们首先比对了代表点个数 N_r 、 k 值以及迭代次数 N_{iter} 在不同取值下的算法性能，选出合适的参数值用来进行后续验证实验。

在人工合成数据集上的可视化实验表明，ECAAD 算法能够准确识别非凸、不规则分布的簇结构（如环形、螺旋形等），且聚类边界清晰，未出现明显的过分割或欠聚类现象，充分证明了其形状适应能力。在 UCI 真实数据集上的对比实验中，ECAAD 在 Acc、ARI、AMI 和 NMI 四项指标上均优于 7 种主流对比算法，尤其在样本量大、类别多的数据集上优势更为显著。运行效率方面，ECAAD 的时间复杂度显著低于基于图的方法，其运行效率同样在大数据集上有更明显的优势。本章的可扩展性测试部分进一步验证了 ECAAD 的实用性。在数据量扩展性实验中，ECAAD 的运行时间随数据规模增长呈近线性趋势，优于 DBSCAN 等二次复杂度算法；在较高维数据测试中，ECAAD 受“维数灾难”影响较小，显著低于对比算法。综合来看，该算法在理论性能和实际应用场景中均具有重要价值。

5 结论

5.1 工作总结

在本文中，我首先调研了任意形状聚类算法的研究现状，将现有方法归纳为三类：基于密度的聚类、基于图结构的聚类和基于采样的聚类。基于密度的聚类通过局部密度划分簇结构，但对全局分布敏感且计算复杂度高；基于图结构的聚类利用图划分技术识别复杂形状，但依赖参数调优且难以扩展；基于采样的聚类通过减少样本数量提升效率，但随机采样可能导致几何形变，影响聚类质量。这些方法的局限性使得它们在处理高维、噪声或非均匀分布数据时效果受限。

为解决上述问题，本文提出了一种面向任意形状数据的高效聚类算法——ECAAD（Efficient Clustering Algorithm for Arbitrary-Shaped Data）。ECAAD 算法的实施过程分为三个阶段：首先，去除数据集中的离群点，进行形状保持采样，使用渐进式最远距离采样的原则保证采样点在样本中均匀分布。随后，利用这些采样点作为初始聚类中心，运行 K-means 算法对数据簇进行凸包划分。基于样本间的同质性构建影响力矩阵，迭代优化使代表性中心点向邻近点移动。最后，使用基于类间最小距离的凝聚聚类对采样点进行聚类操作，并将离群点和原始样本都分配到对应的聚类中。

为验证 ECAAD 算法的有效性，本文在合成数据集和真实数据集上进行了全面实验。结果表明，ECAAD 能够准确识别环形、螺旋形等复杂簇结构，且在聚类精度和运行效率上均优于主流对比算法。此外，可扩展性测试证明 ECAAD 对数据规模和维度具有鲁棒性，适用于实际场景中的大规模高维数据分析。由此可得，本研究为任意形状聚类问题提供了一种兼顾精度与效率的解决方案。

5.2 未来展望

虽然本文提出的面向任意形状数据的高效聚类算法能够在本实验所用的数据集中得到较好的聚类结果，但其仍旧存在一定的局限性：

- （1）ECAAD 算法无法自主确定最佳聚类数量，运行算法时需要手动设置这一关键参数。这一限制在实际应用中会带来显著的操作负担，特别是在处理未知数据结构时，往往需要通过多次试验或借助轮廓系数等评估指标来人工确定合适的聚类数目；

（2） ECAAD算法采用了欧式距离作为相似性度量，这种度量方式的不足会在更高维度的数据样本下体现——随着特征维度的提升，数据点间的距离差异逐渐缩小，导致相似度判别变得不准确，进而影响算法在高维数据上的聚类精度。为解决这一问题，可以考虑引入不同的相似度度量方法，以提升算法在高维空间中的判别能力。

参考文献

- [1] Ester M, Kriegel H P, Sander J, et al. A density-based algorithm for discovering clusters in large spatial databases with noise[C]//Proceedings of the International Conference on Knowledge Discovery and Data Mining, 1996: 226-231.
- [2] Ankerst M, Breunig M M, Kriegel H P, et al. OPTICS: Ordering points to identify the clustering structure[J]. ACM SIGMOD Record, 1999, 28(2): 49-60.
- [3] Campello R J G B, Moulavi D, Sander J. Density-based clustering based on hierarchical density estimates[C]//Proceedings of the Pacific-Asia conference on knowledge discovery and data mining. Berlin, Heidelberg: Springer Berlin Heidelberg, 2013: 160-172.
- [4] Hinneburg A, Keim D A. An efficient approach to clustering in large multimedia databases with noise[C]//Proceedings of the International Conference on Knowledge Discovery and Data Mining, 1998: 58-65.
- [5] Rodriguez A, Laio A. Clustering by fast search and find of density peaks[J]. Science, 2014, 344(6191): 1492-1496.
- [6] Wang Y, Wang D, Zhou Y, et al. VDPC: Variational density peak clustering algorithm[J]. Information Sciences, 2023, 621: 627-651.
- [7] Wang S, Li Q, Zhao C, et al. Extreme clustering—a clustering method via density extreme points[J]. Information Sciences, 2021, 542: 24-39.
- [8] Chen M, Li L, Wang B, et al. Effectively clustering by finding density backbone based-on kNN[J]. Pattern Recognition, 2016, 60: 486-498.
- [9] Zhang X Y, Yun W G. Sharing K-nearest neighbors and multiple assignment policies density peaks clustering algorithm [J]. Journal of Chinese Computer Systems, 2023, 44(1): 75-82.
- [10] Karypis G, Han E H, Kumar V. Chameleon: Hierarchical clustering using dynamic modeling[J]. Computer, 1999, 32(8): 68-75.
- [11] Von Luxburg U. A tutorial on spectral clustering[J]. Statistics and computing, 2007, 17: 395-416.
- [12] Shi J, Malik J. Normalized cuts and image segmentation[J]. IEEE Transactions

- on Pattern Analysis and Machine Intelligence, 2000, 22(8): 888-905.
- [13] Liu H, Wu J, Liu T, et al. Spectral ensemble clustering via weighted k-means: Theoretical and practical evidence[J]. IEEE transactions on knowledge and data engineering, 2017, 29(5): 1129-1143.
 - [14] Wang C, Pan S, Hu R, et al. Attributed graph clustering: A deep attentional embedding approach[J]. arXiv preprint arXiv:1906.06532, 2019.
 - [15] Yue G L, Deng A S, Qu Y P, et al. Stratified multi-density spectral clustering using Gaussian mixture model[J]. Information Sciences, 2023, 633: 182-203.
 - [16] Guha S, Rastogi R, Shim K. CURE: An efficient clustering algorithm for large databases[J]. ACM SIGMOD Record, 1998, 27(2): 73-84.
 - [17] He H, He Y, Wang F, et al. Improved K-means algorithm for clustering non-spherical data[J]. Expert Systems, 2022, 39(9): e13062.
 - [18] Chaoji V, Al Hasan M, Salem S, et al. SPARCL: An effective and efficient algorithm for mining arbitrary shape-based clusters[J]. Knowledge and Information Systems, 2009, 21(2): 201-229.
 - [19] Chaoji V, Li G, Yildirim H, et al. ABACUS: Mining arbitrary shaped clusters from large datasets based on backbone identification[C]//Proceedings of the 2011 SIAM International Conference on Data Mining, 2011: 295-306.
 - [20] Huang H, Gao Y, Chiew K, et al. Towards effective and efficient mining of arbitrary shaped clusters[C]//Proceedings of the 2014 IEEE 30th International Conference on Data Engineering. IEEE, 2014: 28-39.
 - [21] Jain A K. Data clustering: 50 years beyond K-means[J]. Pattern recognition letters, 2010, 31(8): 651-666.
 - [22] Xu R, Wunsch D. Survey of clustering algorithms[J]. IEEE Transactions on neural networks, 2005, 16(3): 645-678.
 - [23] Hastie T, Tibshirani R, Friedman J H, et al. The elements of statistical learning: data mining, inference, and prediction[M]. New York: springer, 2009.
 - [24] Hubert L, Arabie P. Comparing partitions[J]. Journal of classification, 1985, 2: 193-218.
 - [25] Vinh N X, Epps J, Bailey J. Information theoretic measures for clusterings

- comparison: is a correction for chance necessary?[C]//Proceedings of the 26th annual international conference on machine learning. 2009: 1073-1080.
- [26] Fowlkes E B, Mallows C L. A method for comparing two hierarchical clusterings[J]. Journal of the American statistical association, 1983, 78(383): 553-569.
- [27] Bay S D, Schwabacher M. Mining distance-based outliers in near linear time with randomization and a simple pruning rule[C]//Proceedings of ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2003: 29-38.
- [28] Song J, Yue S, Chen M, et al. ST-ADPTC: a method for clustering spatiotemporal raster data based on improved density peak detection[J]. International Journal of Geographical Information Science, 2024, 38(9): 1728-1750.
- [29] 徐晓, 丁世飞, 丁玲. 密度峰值聚类算法研究进展[J]. 软件学报, 2020, 33(5): 1800-1816.
- [30] 牛新征, 司伟钰, 余堃. 基于进化聚类的动态网络社团发现[J]. 软件学报, 2017, 28 (07): 1773-1789.
- [31] 于彦伟, 贾召飞, 曹磊, 等. 面向位置大数据的快速密度聚类算法[J]. 软件学报, 2018, 29(8): 2470-2484.
- [32] 刘吉元, 刘新旺, 蔡志平, 祝恩, 鞠儒生. 数据表示的相关性度量方法[J]. 计算机学报, 2024, 47(7): 1-12.

致 谢

岁月不居，时节如流。一个又一个夏天过去，武汉还是那么燥热，让人想逃离又留恋。这四年我一直在学习、在体验，遇到了形形色色的人，经历了或大或小的事。起笔匆匆，复杂的感情糅杂在一起，无法一一解构。但回想起过去的时光，我要感谢好多人。

首先，由衷感谢我的指导老师黄浩。从论文的选题到开题再到修改完善，每一步都离不开黄老师的耐心指导与宝贵建议。希望老师学术长青，万事顺遂。感谢实验室学长的指导与帮助，使我的论文能够顺利完成。

感谢我的挚友李忆蓉、闫笑涵，以及我的群友和室友。谢谢你们在我脆弱的时候给予陪伴，给我力量。本人不善言辞，拙于表达，但我们始终有理解彼此的默契。我们一起聊天，一起追星，一起跑来跑去，分享彼此的喜悦与痛苦。我会一直珍视我们的友谊。

感谢我的妈妈和家人，求学道路艰难，但你们一直托举我供我读书，支持我去看更大的世界，这让我倍感幸运。

最后，我要感谢泰勒斯威夫特、吴青峰、苏打绿、Hush、焦安溥、twice……你们的音乐与美好品质支撑我走过本科最难捱的时光，让我有勇气一个人战斗。感谢我阅读过的文学和影视作品，你们填充了我单调的生活，拓宽了我的人生。

时间从来不回答，生命从来不喧哗。感谢给予过我帮助和善意的每个人。我不再害怕只有片刻的幸福与满足，不再畏惧失去，因为是片刻的瞬间组成永恒。好消息是，我得继续独自前行了，就像一路走来那样。

